

1 ARTEFATTI DI UNA ESECUZIONE

Summary della traiettoria

OGGETTO DA VALUTARE

- sintomo e simulazione di base
- scenari, azioni e run SPICE
- confronti base-scenario
- risposta o conclusione finale

Ground truth tecnica

RIFERIMENTO INDIPENDENTE

- evidenze richieste e assunzioni
- condizioni di successo
- soluzioni tecnicamente ammissibili
- limiti e conclusioni non supportate

2 PREPARAZIONE E GIUDIZIO



Judge packet

summary + riferimento

- campi rilevanti
- modalità anonimizzata



LLM judge

prompt, rubric e schema fissati

- 0-2** Correttezza diagnostica
- 0-2** Qualità dei test
- 0-2** Interpretazione delle evidenze
- 0-2** Raggiungimento dell'obiettivo
- 0-2** Qualità della conclusione

giudizio motivato dalle evidenze

×42 stesso protocollo: 21 circuiti × 2 modalità

3 RISULTATO STRUTTURATO

Punteggi



cinque criteri da 0 a 2
totale complessivo: 0-10

Esito sintetico



success · partial_success · failure
inconclusive · technical_failure

Eventuali criticità



false_success · unsupported_claim
wrong_interpretation