

Rilevamento di simboli elettrici nei diagrammi

Dalla costruzione del dataset al benchmark su YOLOv7, YOLOv8 e YOLOv11


32 classi

input 1024×1024

15 esperimenti


Messaggio chiave

Il benchmark converge verso **YOLOv11** come famiglia dominante; tra i run completati, **exp11b (aug_v3 strong)** è il miglior punto di partenza operativo per le fasi successive di OCR e ricostruzione dei collegamenti.



Distribuzione classi e bounding box del dataset

Il detector è il primo blocco del sistema: prima si localizzano i simboli, poi si affrontano OCR e collegamenti elettrici.



Perché è importante?

- il detector deve massimizzare copertura e localizzazione, non solo precisione pura;
- le ROI corrette riducono il rumore per OCR e per il parsing dei componenti;
- la scelta finale del run influenza direttamente la qualità delle fasi successive.

Workflow dataset


- annotazione dei simboli elettrici in Roboflow;
- versionamento del dataset e export in formato YOLO;
- uniformazione della risoluzione a 1024×1024 ;
- split mantenuti stabili per confrontare i modelli;
- nelle fasi successive viene usato un dataset detect-only pulito per i benchmark più recenti.

Dati chiave usati nel benchmark finale

32 classi

126 immagini val

1625 istanze val



Esempio di vista sintetica del dataset: classi, densità spaziale e forma delle bbox.

RGB baseline

- export YOLO diretto da Roboflow
- nessuna modifica al contenuto
- riferimento per tutti i confronti

Grayscale

- conversione PIL con `.convert("L")`
- label copiate identiche
- utile per verificare se il colore è davvero necessario

aug_v1 (debole)

- Affine: scale 0.97-1.03
- translate $\pm 3\%$, rotate $\pm 7^\circ$
- brightness/contrast lieve + rumore leggero

aug_v2 compose

- composizione side-by-side di due diagrammi
- gap 10 px e resize+padding a 1024
- perturbazione finale molto piccola

aug_v3 strong

- rotate 25-45°
- translate 8-15%, scale 0.93-1.07
- min_visibility 0.20, noise più marcato

Regola metodologica comune

- le trasformazioni sono applicate solo al training set;
- validation e test restano invariati per mantenere confronti corretti;
- la pipeline compose crea campioni più densi ma altera la distribuzione originale;
- la pipeline strong punta a massimizzare robustezza e generalizzazione del detector.

Setup comune

- Google Colab con GPU Tesla T4;
- img size 1024×1024, batch size 4;
- 100 epoche per tutti i run completati;
- checkpoint di valutazione: best.pt;
- best epoch selezionata sulla metrica mAP@0.5:0.95.

Osservazione

Il confronto è stato progettato come studio a variabile controllata: stesso task, stessa risoluzione, stessa logica di training, cambiando famiglia YOLO oppure variante di dataset.

15 esperimenti completati

	RGB	Gray	aug_v1	aug_v2	aug_v3
YOLOv7	exp01 baseline	exp02 grayscale	exp03 debole	exp04 compose	exp03b forte
YOLOv8	exp05 baseline	exp06 grayscale	exp07 debole	exp08 compose	exp07b forte
YOLOv11	exp09 baseline	exp10 grayscale	exp11 debole	exp12 compose	exp11b forte


Best family run: exp03b · exp08 · exp11b



Lettura rapida

- YOLOv11 occupa tutte le prime cinque posizioni del ranking F1;
- exp11b è il migliore assoluto: F1 = 0.9223;
- exp11 è quasi equivalente, ma con trade-off diverso;
- YOLOv7 migliora molto con aug_v3 strong;
- YOLOv8 resta competitivo, ma non raggiunge i migliori run YOLOv11.

Top F1: exp11b

2°: exp11






Takeaway

- nel quadrante alto-destra dello scatter si concentrano i run YOLOv11;
- su mAP@0.5:0.95 vince exp11b, davanti a exp11 e exp10;
- grayscale aiuta YOLOv11 e, in parte, YOLOv8; la compose è meno stabile.

Trade-off rispetto a exp11




Interpretazione operativa

- exp11 resta il migliore su precision e mAP@0.5;
- exp11b migliora recall, F1 e soprattutto mAP@0.5:0.95;
- per OCR e connessioni è preferibile non perdere simboli e localizzarli in modo più robusto.

Errori da monitorare nei run YOLOv11

- classi più fragili: Antenna, Analog_Meter, Terminal;
- false positive/negative su background da tenere d'occhio;
- la scelta della confidence soglia influisce sul compromesso precision/recall.



Esempio di confusion matrix normalizzata da un run YOLOv11.

Scelta finale

- modello da cui partire: **YOLOv11 exp11b**;
- training consigliato: RGB detect-only + aug_v3 strong;
- in inferenza: export RGB pulito, senza augmentation;
- fallback utile: exp11 quando serve massimizzare precision e mAP@0.5.

Detector scelto: exp11b

Roadmap dopo il detector



Messaggio finale

Il confronto non indica solo quale modello “vince”: mostra anche quali trasformazioni del dataset aiutano davvero il task. Nel tuo caso, la combinazione più promettente è un detector YOLOv11 addestrato su RGB con augmentation forte, e poi usato come base per OCR e parsing topologico.